

2023 Türkiye Depremleri Sonrası Bina Hasar T e s p i t i

C N N v e V i s i o n T r a n s f o r m e r M o d e l l e r i n i n K a r ş ı l a ş t ır m a l ı A n a l i z i

Derin Öğrenme Uygulamaları Dersi Dönem Sonu Projesi

Emre Sebati Yolal

244217003 / Bilişim Sistemleri Mühendisliği Tezli Yüksek Lisans

Muğla Sıtkı Koçman Üniversitesi

emresebatiyolal@posta.mu.edu.tr

Motivasyon ve Problem Tanımı

Afet sonrası hasar tespiti, acil müdahale ve kaynak tahsisi için kritik öneme sahiptir. Geleneksel manuel inceleme yöntemleri zaman alıcı olup, sınırlı insan gücüne bağlıdır.

Uydu ve hava görüntüleri geniş bölgelerin hızlı değerlendirilmesini sağlar, ancak büyük miktardaki görüntü verisinin otomatik yöntemler gerektirir.

Manuel İnceleme Sorunları

Zaman alıcı süreçler ve yetersiz insan kaynağı

Görüntü Verisi Potansiyeli

Uydu ve hava görüntüleri geniş alan kapsamı sağlar

Otomatik Analiz İhtiyacı

Büyük veri setlerinin hızlı işlenmesi gerekir

Hedef: Hasarlı ve hasarsız bina sınıflandırması için otomatik derin öğrenme yaklaşımları geliştirmek

Çalışmanın Amacı ve Araştırma Soruları

Bu çalışma, 2023 Türkiye depremleri sonrası elde edilen bina görüntülerinden hasar tespiti yapmayı amaçlamaktadır. ~~Karşılaştırmalı~~ ^{Karşılaştırmalı} analiz odaklı bu araştırma, uygulama geliştirme yerine model performanslarının sistematik değerlendirilmesine odaklanmaktadır.



Model Karşılaştırması

Az verili senaryoda CNN ve Transformer mimarilerinden hangisi daha başarılıdır?



Transfer Learning Etkinliği

Transfer learning ve finetuning stratejisi bu özel görevde ne kadar etkilidir?



Kritik Metrikler

Afet senaryosu için en önemli metrik olan Recall açısından hangi yaklaşım daha güvenlidir?

 **Önemli Not:** Bu çalışma bir uygulama geliştirme projesi değil, CNN ve Transformer modellerinin sistematik karşılaştırmalı analizidir.

2023 Türkiye Depremleri: Bağlam

Deprem Bilgileri

6 Şubat 2023 tarihinde Türkiye'de ardışık olarak 7.7 ve 7.6 büyüklüğünde iki yıkıcı deprem meydana gelmiştir.

Bu depremler Kahramanmaraş, Hatay, Gaziantep, Adıyaman, Malatya, Diyarbakır, Şanlıurfa, Adana, Osmaniye, Kilis ve Elazığ illeri etkillemiştir.

Geniş çaplı hasar ve yıkımın ardından hızlı hasar değerlendirme ve tespiti kritik bir ihtiyaç haline gelmiştir.

Veri Seti Tanıtımı

Türkiye Earthquake 2023 : Damaged Buildings Dataset

Kaggle platformunda paylaşılan bu veri seti, deprem sonrası hasar tespiti için özel olarak derlenmiştir. Toplam 2735 JPG formatında görüntü içermektedir ve görüntüler değişken boyutlara sahiptir.

Sınıf Dağılımı

- **Hasarlı binalar**1237 görüntü
- **Hasarsız binalar**1498 görüntü

Görece dengeli bir sınıf dağılımı mevcuttur.

Hasarlı Bina Kaynağı

HGM-KURE (Harita Genel Müdürlüğü) sisteminden alınan ekran görüntüleri

Hasarsız Bina Kaynağı

Google Maps platformundan alınan ekran görüntüleri

❏ **Önemli Sınırlılık**Farklı kaynaklardan elde edilen görüntüler olası "domain shift" etkisi yaratabilir. Bu durum sınırlılıklar bölümünde detaylı olarak tartışılacaktır.



Veri Bölümleme Stratejisi

Güvenilir model değerlendirmesi için veri seti stratified sampling (tabakalaştırılmış örnekleme) yöntemiyle üç alt kümeyle ayrılır. Bu yöntem, her alt kümede sınıf oranlarının korunmasını sağlar.

Eğitim Seti (Train)

1914 görüntü (%70)

Model parametrelerinin öğrenilmesi için kullanılır

Doğrulama Seti (Validation)

410 görüntü (%15)

Hiperparametre ayarı ve early stopping için kullanılır

Test Seti (Test)

411 görüntü (%15)

Nihai performans değerlendirmesi için kullanılır

Neden Bu Yaklaşım Önemli?

- Test seti eğitim sürecine hiç karışmaz
- Model seçimi validation setinde yapılır
- Sonuçlar daha güvenilir ve genellenebilir olur
- Overfitting riski minimize edilir

Her üç alt kümede de hasarlı bina oranı yaklaşık %45.2 olarak korunmuştur, bu da dengeli bir değerlendirme sağlamaktadır.

Genel Yöntem Akışı

Çalışmamızda sistematik bir pipeline izlenmiştir. Her aşama dikkatle tasarlanmış ve standardize edilmiştir.

01

Veri Yükleme ve Normalizasyon

Görüntüleri yükle ve ImageNet istatistiklerine göre normalize et

02

Veri Artırma

Eğitim seti için augmentation teknikleri uygula

03

Model Seçimi

Pre-trained CNN veya Transformer modelini seç

04

Frozen Training

Backbone dondurularak sadece sınıflandırma katmanını eğitilir

05

Fine-tuning

Katmanlar açılarak düşük öğrenme oranıyla ince ayar yapılır

06

Early Stopping

Validation F1 skoruna göre en iyi model seçilir

07

Test Değerlendirmesi

Test setinde nihai metrikler hesaplanır

08

Görselleştirme ve Karşılaştırma

ROC eğrileri, confusion matrix ve karşılaştırma grafikleri oluşturulur

Pre-training ve Transfer Learning Stratejisi

Sıfırdan model eğitimi yerine transfer learning yaklaşımı tercih edilmiştir. Bu seçimin arkasında güçlü nedenler bulunmaktadır

Neden Sıfırdan Eğitim Tercih Edilmedi?

- Veri seti görece küçüktür (2735 görüntü)
- Derin ağlar milyonlarca parametre içerir
- Az veriyle overfitting riski çok yüksektir
- Yakınsama ve stabilite sorunları yaşanabilir



ImageNet Pre-training

1.4 milyon görüntü ile öğrenilmiş genel görsel temsiller



Transfer Edilen Bilgi

Kenar, doku, şekil ve yüksek seviye paternler



Deprem Hasarına

Adaptasyon

Az veriyle spesifik göreve uyarlama

Pre-trained modeller, ImageNet gibi büyük veri setlerinde öğrenilen genel görsel temsillerden yararlanarak, az verili senaryolarda daha stabil ve güvenilir sonuçlar sağlar.

İki Aşamalı Fine-tuning Stratejisi

Eğitim süreci iki farklı aşamada gerçekleştirilmiştir. Her aşamanın kendine özgü amacı ve hiperparametreleri bulunmaktadır.

1 Frozen Training

Backbone katmanları dondurulur

- Sadece sınıflandırma katmanı (head) eğitilir
- Yüksek öğrenme oranı kullanılabilir
- Hızlı adaptasyon sağlanır
- Pre-trained özellikler korunur

Amaç: Modele yeni sınıflandırma görevini tanıtmak

2 Full Fine-tuning

Tüm katmanlar açılır (unfreeze)

- Backbone katmanları da güncellenmeye başlar
- Çok daha düşük öğrenme oranı kullanılır
- Öğrenilen temsiller deprem hasarına özelleşir
- Hassas ayarlama (fine-tuning) gerçekleşir

Amaç: Genel görsel temsilleri göreve özelleştirmek

Early Stopping Mekanizması

Validation F1 skoru izlenerek eğitim kontrol edilir. Patience değeri 4 epoch olarak belirlenmiştir. Eğer 4 ardışık epoch boyunca validation F1 skorunda iyileşme görülmezse, eğitim otomatik olarak durdurulur ve en iyi performans gösteren model ağırlıkları geri yüklenir.

Veri Artırma ve Ön İşleme Teknikleri

Eğitim Seti Augmentation

Modelin farklı görüntü koşullarına dayanıklılığını artırmak için çeşitli veri artırma teknikleri uygulanmıştır:

- **Random Rotation**Rastgele açılarla döndürme
- **Horizontal Flip**Yatay yansıma
- **Vertical Flip**Dikey yansıma
- **Random Crop/Zoom**Rastgele kırpma ve yakınlaştırma
- **Brightness Jitter**Parlaklık varyasyonları
- **Contrast Jitter**Kontrast değişimleri

1

Normalizasyon

Tüm görüntüler ImageNet mean ve standard deviation değerleri kullanılarak normalize edilmiştir. Bu, pretrained modellerin beklediği girdi dağılımına uyum sağlar.

2

Farklı Koşullara Dayanıklılık

Augmentation sayesinde model, farklı çekim açıları, aydınlatma koşulları ve görüntü kalitelerine karşı daha robust hale gelir.

3

Overfitting Azaltma

Veri çeşitliliği artırılarak, modelin eğitim verilerini ezberlemesi önlenir ve genelleme kapasitesi güçlendirilir.

Değerlendirilen Model Mimarileri

Çalışmada CNN ve Transformer tabanlı toplam beş farklı derin öğrenme mimarisi karşılaştırılmıştır. Her model ImageNet üzerinde eğitilmiş ağırlıklarla başlatılmıştır.

CNN Modelleri

ResNet50

Residual bağlantılar ile derinlik sorunu çözen klasik mimari

- 50 katman
- ~25M parametre
- Skip connections

DenseNet121

Yoğun bağlantılar ve özellik yeniden kullanımı

- 121 katman
- ~8M parametre
- Dense connections

EfficientNet -B0

Bileşik ölçekleme ile optimize edilmiş mimari

- Compound scaling
- ~5M parametre
- Efficient architecture

Transformer Modelleri

ViT-B/16

Vision Transformer temel mimarisi

- 16x16 patch boyutu
- ~86M parametre
- Pure attention

Swin Transformer (Tiny)

Hiyerarşik yapı ve shifted windows

- Window-based attention
- ~29M parametre
- Hierarchical design

 **Adil Karşılaştırma Protokolü:** Tüm modeller aynı veri bölümlmesi, aynı augmentation stratejisi, aynı değerlendirme metrikleri ve aynı test protokolü ile değerlendirilmiştir.

Değerlendirme Metrikleri ve Önemi

Model performansını çok boyutlu değerlendirmek için beş farklı metrik kullanılmıştır. Afet senaryosu bağlamında her metrik için bir önemi vardır.



Accuracy (Doğruluk)

Tüm tahminler içinde doğru sınıflandırmaların oranı. Genel performans göstergesi olarak kullanılır ancak dengesiz veri setlerinde yanıltıcı olabilir.



Precision (Kesinlik)

"Hasarlı" olarak tahmin edilen binaların gerçekten hasarlı olma oranı. Yanlış alarm oranını kontrol eder.



Recall (Duyarlılık)

Gerçekte hasarlı olan binaların ne kadarının tespit edildiğini gösterir. **Afet senaryosu için EN KRİTİK metriktir** - hasarlı bir binayı kaçırmak hayati risk taşır.

F1-Score

Precision ve Recall'ın harmonik ortalaması. Her iki metriği dengeli şekilde değerlendirir ve genel performansı tek bir sayıda özetler.

ROC -AUC

Farklı eşik değerlerinde modelin sınıfları ayırt etme gücünü ölçer. 1'e yaklaştıkça model daha güçlü ayırım yapar.

Kritik Vurgu Afet yönetimi bağlamında Recall metriği en yüksek önceliğe sahiptir. Hasarlı bir binayı "hasarsız" olarak sınıflandırmak, yanlış bir değerlendirme olarak kabul edilemez bir risktir. Bu nedenle yüksek Recall değeri, yüksek Precision'dan daha kritiktir.

Transformer Modelleri: ViT ve Swin Sonuçları

Vision Transformer ve Swin Transformer mimarileri test setinde olağanüstü performans sergilemiştir. Her iki model de hasarlı binaları mükemmel şekilde tespit etmiştir.

0.9854

ViT Accuracy

Vision Transformer genel doğruluk

0.9927

Swin Accuracy

Swin Transformer genel doğruluk

1.00

Recall (İkisi de)

Hiç hasarlı bina kaçırılmadı

0.9998

Swin AUC

Neredeyse mükemmel ayırım gücü

Detaylı Metrik Karşılaştırması

Metrik	ViT-B/16	Swin-Tiny
Accuracy	0.9854	0.9927
Precision	0.9698	0.9843
Recall	1.0000	1.0000
F1-Score	0.9841	0.9920
ROC-AUC	0.9992	0.9998

Yorumlama: Her iki Transformer modeli de **Recall=1.0** elde ederek hasarlı binaları hiç kaçırmamıştır. Swin Transformer ise F1 ve ROC-AUC metriklerinde ViT'ye göre marjinal üstünlük göstermiştir.

Bu sonuçlar, Transformer mimarilerinin görsel hasar tespiti görevinde son derece etkili olduğunu ortaya koymaktadır.

CNN Modelleri: ResNet, DenseNet ve EfficientNet Sonuçları

Üç farklı CNN mimarisi test edilmiştir. DenseNet121 en güçlü CNN performansını sergilerken, EfficientNet-B0 beklenmedik şekilde daha zayıf kalmıştır.




ResNet50 Recall

Yüksek tespit oranı



DenseNet121 Recall

En iyi CNN performansı



EfficientNet Recall

Görece düşük performans

CNN Modelleri Detaylı Karşılaştırma

Metrik	ResNet50	DenseNet121	EfficientNet-B0
Accuracy	0.9781	0.9927	0.9709
Precision	0.9688	0.9895	0.9784
Recall	0.9892	0.9946	0.9624
F1-Score	0.9787	0.9920	0.9702
ROC-AUC	0.9973	0.9997	0.9923

Önemli Gözlemler

DenseNet121: CNN modelleri arasında açık ara lider. Tüm metriklerde güçlü performans göstermiştir ve Swin Transformer ile rekabet edebilecek seviyededir.

ResNet50: Dengeli ve güvenilir performans. Recall metriğinde yüksek skor elde etmiştir.

EfficientNet-B0: Diğer modellere göre daha zayıf kalmıştır. Özellikle Recall metriğindeki düşüklük (0.9624) afet senaryosu için endişe vericidir.

EfficientNet'in görece zayıf performansı şaşırtıcıdır, çünkü bu mimari genellikle parametre verimliliği ve yüksek doğrulukla bilinir. Bu durum, veri setinin özel karakteristikleri veya transfer learning dinamikleri ile ilişkili olabilir.

CNN vs Transformer: Karşılaştırmalı Analiz

Tüm modellerin sistematik karşılaştırması, Transformer ve CNN mimarileri arasındaki performans farklarını ortaya koymaktadır.

En İyi Performans: Transformer Tarafı

Swin Transformer

F1-Score:0.9920

Recall:1.0000 ★

ROC-AUC:0.9998

Mükemmel hasar tespiti hiç hasarlı bina kaçırmadı

En İyi Performans: CNN Tarafı

DenseNet121

F1-Score:0.9920

Recall:0.9946

ROC-AUC:0.9997

Güçlü CNN alternatifi Swin'e çok yakın performans

1

2

3

F1-Score Benzerliği

Swin ve DenseNet121 neredeyse identik F1 skoru elde etmiştir (0.9920)

Kritik Fark: Recall

Swin **Recall=1.0** DenseNet Recall=0.9946 - küçük ama önemli fark

Afet Perspektifi

Hasarlı bina kaçırmama açısından Swin daha güvenli profil sunar

Karar Noktası F1-Score ve genel performans metrikleri benzer olsa da, afet yönetimi perspektifinden "**hasarlı bina kaçırmama**"nın kritik faktördür. Bu bağlamda, **Swin Transformer'ın Recall=1.0 performansı** onu daha güvenli ve tercih edilir bir seçenek haline getirmektedir. Bununla birlikte, DenseNet121 güçlü bir CNN alternatifi olarak öne çıkmaktadır.

Tüm modellerin performansları 0.97'nin üzerindedir, bu da transfer learning yaklaşımının bu görevde son derece etkili olduğunu göstermektedir.

Tartışma: Sonuçlar Neden Bu Kadar Yüksek?

Test setinde elde edilen metrikler (özellikle ROCAUC değerlerinin 0.999'un üzerine çıkması) ilk bakışta şüphe uyandırabilirdir. Sonuçların gerçekçiliğini ve bağlamını tartışmak önemlidir.

Olası Açıklamalar

1 Sınıflar Görsel Olarak Ayırt Edici

Hasarlı ve hasarsız binalar arasında belirgin görsel farklılıklar bulunmaktadır. Hasar, çatlaklar, çökmeler gibi özellikler CNN ve Transformer modellerinin güçlü olduğu pattern tanıma alanına girer.

2 Transfer Learning Etkinliği

ImageNet pre-training, bina yapılarını ve genel görsel özellikleri çok iyi öğrenmiştir. Bu bilgi, deprem hasarına kolayca transfer edilmiştir.

3 Veri Seti Karakteristikleri

Veri setinin görece homojen özelliklere sahip olması ve sınıflar arası net ayrımlar, yüksek performansı kolaylaştırmıştır.



Domain Shift Riski

Hasarlı görüntüler HGMKURE'den, hasarsız görüntüler Google Maps'ten alınmıştır. Bu farklı kaynak sorunu, modellerin kaynak özelliklerini öğrenmiş olabileceği anlamına gelir (domain bias).



Genelleme Sınırlılığı

Modeller bu spesifik veri setinde mükemmel çalışsa da, farklı şehirler, farklı depremler, farklı sensörler veya farklı çekim koşullarında performans düşebilir.

❏ **Dürüst Değerlendirme:** ROCAUC değerlerinin tavana yapması (0.999+) gerçek dünya karmaşıklığını tam yansıtmayabilir. Bununla birlikte, protokol altında CNN ve Transformer karşılaştırmasının geçerliliği korunmaktadır. Sonuçlar, veri setinin ayırt edici doğasını ve transfer learning etkinliğini desteklemektedir.

Sonuçlar ve Ana Çıkarımlar

Bu çalışma, 2023 Türkiye depremleri sonrası bina hasar tespiti için CNN ve Transformer modellerinin sistematik karşılaştırmasını göstermektedir. Elde edilen bulgular, derin öğrenme yaklaşımlarının bu kritik görevdeki potansiyelini ortaya koymaktadır.



Transfer Learning Etkinliği

Pre-training ve fine-tuning stratejisi, az verili senaryoda son derece etkili olmuştur. Tüm modeller 0.97'nin üzerinde performans elde etmiştir.



Swin Transformer Üstünlüğü

Swin Transformer **Recall=1.0** ile en güvenli profili sunmuştur. Hiç hasarlı bina kaçırmaması, afet yönetimi için kritik bir avantajdır.



DenseNet121 Güçlü Alternatif

CNN mimarileri arasında DenseNet121 öne çıkmıştır. Recall=0.9946 ile Swin'e çok yakın performans göstermiştir.



EfficientNet -B0 Yetersizliği

Parametre verimliliğine rağmen, EfficientNet-B0 bu görevde beklenenden düşük performans sergilemiştir (Recall=0.9624).

Model Karşılaştırması Özeti

Model	F1	Recall
Swin Transformer	0.9920	1.0000
DenseNet121	0.9920	0.9946
ViT-B/16	0.9841	1.0000
ResNet50	0.9787	0.9892
EfficientNet-B0	0.9702	0.9624

Tek Cümlelik Karar: Afet odaklı senaryolarda, hasarlı bina kaçırmama (Recall) önceliği göz önüne alındığında, **Transformer yaklaşımı (özellikle Swin Transformer)** en güvenli ve uygun bir seçimdir.

Gelecek Çalışmalar ve Öneriler

Bu çalışma binary sınıflandırma üzerine odaklanmıştır. Gelecek araştırmalar için çeşitli yönlerde genişleme ve derinleştirme mevcuttur.

1

Multi-Class Hasar Seviyeleri

İkili sınıflandırma yerine, hasar seviyelerini kategorize eden çok sınıflı bir yaklaşım geliştirilmesi: hasarsız, hafif hasar, orta hasar, ağır hasar, tamamen yıkılmış.

2

Farklı Bölge ve Deprem Validasyonu

Modellerin farklı coğrafi bölgelerde, farklı deprem senaryolarında ve farklı bina tiplerinde test edilmesi. Bu, domain shift probleminin analizi ve genelleme kapasitesinin değerlendirilmesi için kritiktir.

3

Açıklanabilirlik Analizi

CNN modelleri için GradCAM, Transformer modelleri için attention map görselleştirmeleri ile modellerin hangi özelliklere odaklandığının anlaşılması.

4

Stabilite ve Güvenilirlik Testleri

Çoklu seed ile eğitim, cross-validation, ve ensemble yöntemleri kullanarak modellerin stabilite ve güvenilirlik analizinin yapılması.

Ek Araştırma Alanları

- Semi-supervised learning:** Etiketlenmemiş verilerden yararlanma
- Active learning:** En bilgilendirici örnekleri seçme
- Multi-modal fusion:** Farklı sensör verilerini birleştirme
- Real-time deployment:** Gerçek zamanlı sistemlere entegrasyon
- Uncertainty quantification:** Tahmin belirsizliğinin ölçülmesi

Pratik Uygulamalar

- Mobil ve edge cihazlarda çalışabilen hafif modeller
- Afet yönetim sistemleriyle entegrasyon
- Gerçek zamanlı hasar değerlendirme dashboardları
- Diğer afet türlerine (sel, yangın) genelleme

Teşekkürler

S o r u l a r ı n ı z ı ç i n h a z ı r ı m

Bu sunumu dinlediğiniz için teşekkür ederim. Çalışmayla ilgili sorularınızı ve geri bildirimlerinizi bekliyorum.

İle t iş im

E-posta: emresebatiyolal@posta.mu.edu.tr

Github: github.com/esyolal

Linkedin: linkedin.com/esyolal

K a y n a k l a r

Veri seti: Kaggle - Türkiye Earthquake 2023

Modeller: PyTorch, Timm kütüphanesi